基于双目三维感知的工业工件抓取实证研究

An Empirical Study of Stereo Perception and
Grasp Generation for Industrial Manipulation

yubin qu

2026 年 10 月 14 日

摘要

基于双目感知的工业工件抓取需要将深度估计、抓取生成与机械臂执行连接起来，单独评价感知误差或候选位姿难以说明整条流程的任务完成情况。本文开展模块替换的受控仿真实验，在统一图像、标定和点云接口下，比较七种双目方法与五种抓取模型组成的十一种配置。数据集包含轴套和安装块两类共八件工件，覆盖单件、邻件及料框三种条件，共七十二个场景。实验评价五百零四份点云和七百九十二组候选，并在 FANUC + Isaac Sim、Franka + Isaac Sim 与 Franka + MuJoCo 三个平台、两组摩擦条件下完成一千二百四十四次完整机械臂物理执行。结果表明，所有点云均超过接口点数下限，但两毫米近表面点比例为 6.2%–92.9%，点数充足并不代表目标表面恢复准确。固定 GraspGen 时，FoundationStereo 在三个平台的默认材料条件下分别成功 42/72、52/72 和 17/72；固定 FoundationStereo 时，GraspGen 的成功数也高于当前接入的其他抓取模型。阶段分析显示，候选筛选与路径检查限制可执行任务数，执行阶段的抬升保持和禁止接触进一步影响最终结果。这些结果说明，工业抓取模块的选择需要同时比较点云质量、计划可用性和完整物理执行，并在实际工位配置下核对候选、工具与接触条件。本文公开输入、逐任务记录和分析代码，为模块比较和失败诊断提供可复核材料。

1 Introduction

基于视觉的机械臂操作利用相机观测工件与工作空间，为上料、分拣和装配等任务确定操作对象与动作。围绕视觉信息如何参与动作决策，本文从三条代表性技术路线介绍研究背景。第一条是基于双目三维感知的模块化抓取：由标定后的左右图像估计视差与深度，生成具有实际尺度的点云，再预测夹爪位置、姿态和开口，交由运动规划与控制模块执行；FoundationStereo 和 GraspGen 分别提供了其中的深度估计与抓取生成方法 [1, 2]。第二条是基于世界模型的操作：从观测与交互数据学习环境状态及动作引起的变化，再利用预测的状态演化学习策略或选择动作；例如 DayDreamer 在学习到的世界模型中预测动作后果并训练控制策略，在真实机械臂上完成基于相机图像的拾放 [3]。第三条是基于视觉–语言–动作（vision-language-action，VLA）模型的操作：联合图像和语言指令生成机器人动作，将任务语义理解与动作预测结合；RT-2 将动作编码为词元进行预测，Physical Intelligence 团队的 π_0 则利用流匹配生成连续动作序列 [4, 5]。这三条路线分别强调显式几何、动作后果预测和视觉语言条件下的动作生成，相关模块也可以组合使用。

本文聚焦第一条路线在工业机械臂工件抓取中的应用，研究从双目图像、点云到抓取生成与执行的模块衔接。该路线显式输出工件几何、抓取位姿和运动路径，便于结合相机标定、夹爪尺寸、关

节限制及工位障碍逐阶段检查。面向工业工位的算法选型，仍需要系统的实证研究说明点云生成方法与抓取模型组合后的执行表现。FoundationStereo、Contact-GraspNet 和 GraspGen 等工作分别提供了深度估计或抓取性能证据 [1, 6, 2]，但仅凭各自在不同对象、传感器和机器人配置上的评价，尚不足以回答同一工业工位中替换某个模块后，最终抓取成功率会怎样变化。工件的孔、棱边、邻件遮挡和料框边界会同时改变可见几何与机械臂接近空间，点云误差、目标提取、抓取候选和运动约束也会共同作用于执行结果。因此，本文关注的研究空白是统一工业工件、相机输入和执行规则下的模块比较证据：不同方法生成的点云质量如何，这些差异怎样对应下游抓取结果，以及固定相同点云时不同抓取模型的表现如何。

针对这一研究空白，本文开展面向工业工件的模块替换受控仿真实验。实验使用轴套 / 隔套和安装块两类共 8 件工件，构建包含单件、邻件和料框条件的 72 个场景，比较七种双目感知方法和五种抓取模型组成的十一条配置。首先评价点云的表面误差、可见覆盖和目标来源比例；随后固定 GraspGen 比较双目方法，并固定 FoundationStereo 比较抓取模型。抓取任务分别在 FANUC + Isaac Sim、Franka + Isaac Sim 和 Franka + MuJoCo 中评价，各环境内采用共同的工具、规划和控制设置，两个 Franka 环境进一步复用相同关节路径。实验将每个场景的点云、候选、路径和物理执行结果关联起来，以全场景抓取成功率及阶段记录分析模块替换与环境配置下的结果差异。

本文的贡献包括以下三项。

- 建立面向工业工件抓取的统一模块评测设计。在相同双目图像、相机标定和点云接口下，通过固定抓取模型与固定感知方法的两组对照，比较七种双目方法和五种抓取模型组成的十一种配置，并关联点云、候选、计划及物理执行记录，为工业系统的模块替换提供共同评价依据。
- 提供点云质量与抓取成功率相联系的实证发现。基于 72 个场景及三个仿真实验环境，分析点数、表面误差和覆盖率与后续抓取表现的关系，报告不同配置的成功率及失败阶段，说明点数充足仍可能伴随几何偏差，且同一感知与抓取组合的执行表现会随环境配置变化。
- 共享工业工件数据与可复核的实验材料。公开双目 RGB、相机标定、工件几何、评价真值、模型与参数配置、成功和失败记录及分析代码[1]，使读者能够按场景核对模块输出、重新计算结果表，并以相同数据扩展方法比较。

本文其余部分组织如下：节 2 介绍双目感知、抓取生成及相关评价工作；节 3 给出研究问题、实验数据、基线方法、执行环境与评价指标；节 4 至节 6 依次报告点云质量、固定抓取模型的感知比较和固定感知方法的抓取模型比较；节 7 讨论对工业界和学术界的启示及有效性威胁；节 8 总结研究并说明未来工作。

2 相关工作

2.1 Stereo Perception and Point Cloud Construction

双目感知通过左右图像中的对应关系恢复尺度明确的三维几何。对经过校正的图像，横向视差 d、焦距 f 和基线长度 b 决定深度 $z = fb/d$；随后利用相机内参反投影，并通过外参转换到工位坐标系。因此，匹配结果和相机标定共同决定点云的位置与形状。对于带孔轴套，外轮廓的深度偏差会移动夹爪接触面，孔边缘的错误匹配可能填补实际空隙，背景点也可能被投影到目标区域。这些

[1] https://github.com/warmjademe/Robotic-Grasping-BasedOn-TwoCamerasSensing

变化对抓取的影响取决于误差出现的位置以及夹爪的接近方向。

传统双目方法通过手工定义的匹配代价和几何约束估计视差。局部块匹配比较有限窗口内的图像信息，其表现受纹理和窗口尺度影响；小型视觉系统中的立体匹配工作为这类实现提供了基础 [7]。SGM 沿多个方向累积匹配代价，以视差变化惩罚约束局部匹配，同时保留一定的深度边界 [8]。本文采用 OpenCV StereoBM 与 StereoSGBM 的具体实现，形成无需预训练权重的两种比较基线。

学习式方法进一步学习图像特征、匹配代价及其更新方式。PSMNet 将空间金字塔池化与三维卷积结合，利用多尺度上下文构造和聚合代价体 [9]；GwcNet 按通道分组计算左右特征的相关性，以多组匹配信息表示视差候选 [10]。RAFT-Stereo 通过多层循环更新逐步修正视差 [11]，IGEV-Stereo 在迭代过程中查询编码几何与上下文的体表示 [12]。FoundationStereo 面向跨场景双目估计，通过大规模预训练及单目先验增强图像匹配 [1]。这些方法改进的对象均包括图像对应关系，但点云还要经过反投影、目标区域选择和过滤才能进入抓取模块。本文将这些处理后的实际输入作为评价对象，以连接双目方法的输出与后续任务结果。

2.2 Grasp Poses, Motion Plans, and Physical Execution

抓取位姿指定夹爪在三维空间中的位置和朝向，运动计划则描述机械臂如何到达该位姿。抓取模型通常还输出开口及候选评分，六自由度抓取生成方法可从同一观测产生多个不同朝向的候选 [13, 6]。对于工业工位，一个贴近工件表面的候选可能超出夹爪开口、违反机械臂关节限制，或者需要从料框壁穿过。运动规划负责检查这些条件并生成接近和抬升动作；机械臂控制接口据此跟踪关节或末端轨迹。因此，调用机械臂接口之前仍需确定夹法及其可执行运动。

完整抓取还取决于接触形成后的物理行为。以轴套两侧的平行夹持为例，末端到达给定位置后，如果两指没有形成有效夹持，工件仍可能停留在台面；即使工件被抬起，也可能在保持过程中滑落或与周围物体发生禁止接触。Dex-Net 2.0 和 GPD 分别通过实体机器人实验检验学习式抓取评分与点云抓取检测 [14, 15]，表明这一几何感知与抓取决策路线具有可执行的实例。本文在评价中继续区分候选位姿、路径通过和物理任务完成，使成功标签对应实际记录的接近、闭合、抬升及保持过程。

2.3 Grasp Generation and Empirical Evaluation

基于点云的抓取方法采用不同方式表示候选及学习抓取质量。GPD 先在局部几何中采样夹爪位姿，再对候选附近的观测进行学习式分类 [15]。6-DOF GraspNet 使用变分生成模型提出候选，并由评价网络评分和修正 [13]；Contact-GraspNet 从场景点云中的接触点出发，预测夹爪方向和宽度 [6]。GraspNet-Baseline 基于统一抓取数据的网络分解预测接近方向、旋转角和抓取参数 [16]。GraspGen 使用扩散模型生成抓取，并以包含生成器候选的训练过程构建判别器 [2]。这些方法既有采样与评分组合，也有直接预测、变分生成和扩散生成，提供了具有不同候选分布的比较对象。

已有评价为抓取方法提供了几何和机器人实验依据，但输入及执行条件会影响指标的解释。GraspNet-1Billion 以真实 RGB-D 场景和统一抓取标注支持方法比较 [16]，GraspGen 同时报告仿真与真实机器人实验 [2]。本文比较的是这些模型通过共同接口接入同一双目工位后的结果：对象点云或场景点云、原生夹爪坐标和开口语义均保留来源记录，再转换到共同的平行夹爪表示。各方法评分只用于本模型内排序，执行成败由统一物理判据确定。这一设计使比较对象从单个候选预测器扩展到具体感知、抓取及机械臂配置的组合。

2.4 研究空白

已有研究为三维感知和机器人抓取提供了方法与评价依据，但各项评价覆盖的系统环节不同。FoundationStereo 比较双目深度估计，并展示真实场景中的点云结果，包括螺母和螺栓等对象 [1]；GraspNet-1Billion 提供真实 RGB-D 场景、抓取标注和统一的抓取位姿评价 [16]；GraspGen 则在仿真和真实机器人上验证抓取生成方法 [2]。这些工作已研究感知或抓取的实际表现，本文进一步关注这些模块组合后在工业机械臂任务中的执行结果。

工业工位的方法选择需要知道：同一批工件和摆放条件下，更换感知或抓取模块后，机械臂最终能否完成抓取。从上述代表性工作的评价范围看，仍需补充统一工业工件、相机输入、夹爪和执行规则下的受控比较，将点云误差与覆盖、抓取候选、路径可执行性和物理抓取成功逐任务关联起来。单件、邻件和料框条件下的可见表面与接近空间不同，方法的离线几何或候选评价也需要与这些条件下的执行结果对应。这类证据有助于判断失败发生在感知、抓取生成、运动规划还是夹持阶段，并支持工业系统的模块选择与调整。

本文通过点云质量评价及两组模块替换实验补充上述比较证据。两组实验分别固定 GraspGen 比较感知方法、固定 FoundationStereo 比较抓取模型，在三个仿真实验环境中覆盖单件、邻件和料框条件，以规定任务的抓取成功率评价整条执行流程。当前实验使用合成工业形状和物理仿真，先检查模块组合在受控条件下的表现；当前实验以工业形状代理和仿真接触描述这一任务，真实金属表面、相机噪声与硬件标定的影响在有效性威胁中讨论。

3 Empirical Study Design

本文采用模块替换的受控仿真实验，在同一场景集合上分别固定抓取模型或双目感知方法，以逐任务配对记录比较替换模块后的结果。

3.1 Study Scope

本文界定的研究场景是工业工位中基于抓取前双目图像的静态刚性工件抓取。工件放置在工作台或料框内，固定基座机械臂配备平行两指夹爪，一对已标定且位置固定的相机观测抓取区域。每次任务指定一个目标工件，目标是在允许接触条件下完成接近、夹紧、抬升和保持。视觉信息在机械臂动作开始前采集，执行期间按预先选定的运动计划完成抓取。实验以合成工业工件和仿真工位实现该场景，并保留各阶段输出与执行记录。

以从邻近工件旁夹起一个带孔轴套为例，任务开始时轴套静置在工作台上，旁边的工件可能遮挡部分表面并限制夹指的接近空间。左右相机从不同视点拍摄同一摆放状态，双目方法根据两幅图像估计深度，结合标定参数将可见表面转换为工位坐标系中的三维点。经过统一的目标区域提取和过滤后，目标点云被送入抓取模型，生成若干夹爪位置、朝向和开口候选；一种可能的候选是让两指分别接触轴套外壁两侧，其他候选可以采用不同的接近方向。路径程序随后检查候选是否满足夹爪开口和机械臂关节限制，以及接近、闭合和抬升过程是否受到工作台或邻近工件阻挡，并从通过检查的候选中选定执行方案。

机械臂执行该方案时，先将张开的夹爪移动到预抓取位置，再接近轴套、闭合夹指并向上抬升，最后在目标高度保持。评价程序依据记录的机械臂末端状态、工件高度和接触信息，判断是否完成

到位、抬升保持及允许接触要求。如果没有候选通过路径检查，或执行后工件未被稳定夹起，该任务仍保留在结果中，并记录相应的失败阶段。图 1 概括了这一示例的处理过程。单件条件去除邻近障碍，邻件条件引入遮挡与相邻工件，料框条件加入壁面约束；实验在这些摆放条件下复用相同输入，分别替换双目方法或抓取模型，比较各阶段输出与最终抓取结果。

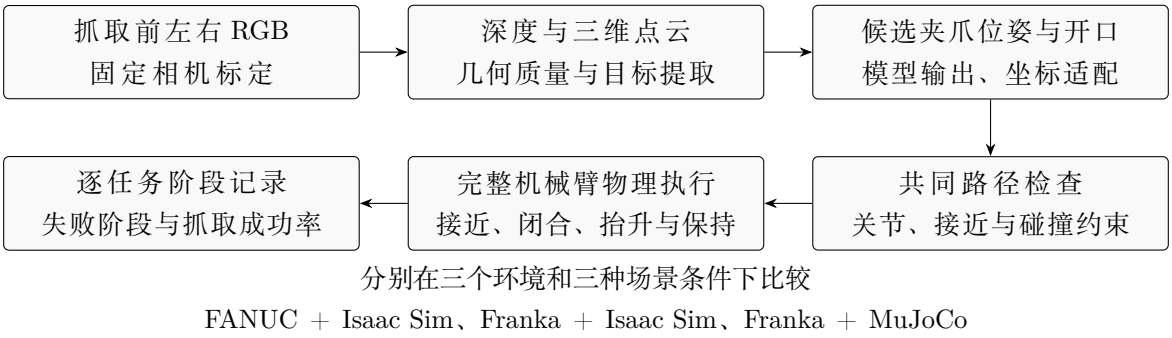


图 1: 实验流程及评价职责。抓取模型给出位姿，路径程序给出运动；完整物理执行独立记录接触、抬升与禁止碰撞。

3.2 Research Questions

本文从几何输入质量和两类模块的替换效果出发，提出三个研究问题。

RQ1. 不同双目感知方法生成的工件点云质量如何?

RQ2. 固定 GraspGen 时，不同双目感知方法的抓取效率如何?

RQ3. 固定 FoundationStereo 时，不同抓取模型的抓取成功率如何?

三个研究问题依次从几何输入质量进入抓取任务，并通过两组固定模块的比较分析感知与抓取生成的作用。RQ1 在相同左右图像、相机标定和目标提取步骤下，比较点数、表面误差、可见覆盖与目标来源比例，为后续结果提供逐场景的几何证据。在此基础上，RQ2 固定 GraspGen 以及每个环境内的规划和控制设置，仅替换双目方法，观察不同点云对应的抓取成功率；其中“抓取效率”指既定任务的成功比例。RQ3 则固定 FoundationStereo 输出以及每个环境内的夹爪、规划和控制设置，仅替换抓取模型，比较相同几何输入下的抓取成功率。因此，RQ1 说明输入几何的差异，RQ2 和 RQ3 分别考察两类模块替换后的任务表现；结合候选、路径和物理执行记录，可以进一步定位各阶段的失败。

3.3 实验数据集

数据集面向工业机械臂在工位上进行零件上料、分拣和料框取件的应用场景，评价平行两指夹爪对刚性工件的抓取（见表 1）。实验数据集包含轴套 / 隔套和安装块两类程序化工业形状，每类四个尺寸变体，共 8 件工件。工件包含孔、平面和棱边等工业零件常见结构，用于观察几何误差、邻件遮挡及料框边界对感知和执行的影响。每件设置三个位姿，每个位姿包含单件、邻件和料框三种条件，共 $8 \times 3 \times 3 = 72$ 个场景，每种条件各 24 个。每场景输入一对左右 RGB 图像，共 144 张；七种感知方法和三个仿真实验环境使用相同的 72 个场景清单。渲染输入为 640×480 RGB，双目基线为 60 mm、水平和垂直焦距均为 700 像素，采用无畸变的合成针孔相机，感知输入为固定左右

图像及其标定参数。真值网格、对象身份、深度和位姿用于离线评价及物理环境构造。

表 1: 面向工业工位的工件抓取评测数据集。每类场景均包含轴套 / 隔套和安装块两类共 8 件工件、每件 3 个位姿。工件为程序化工业形状，场景采用合成双目图像和物理仿真。

场景类型	对应工业作业	工件摆放与抓取约束	场景数
单件	台面工件上料	目标工件单独放置于台面，比较不同位姿下的表面恢复、夹持位置选择及台面接近约束。	24
邻件	相邻工件分拣	目标旁存在其他工件，评价非目标点混入、邻件遮挡与夹爪接近时的避碰要求。	24
料框	料框内工件取件	目标位于带壁面约束的料框场景，评价壁面对可见表面、夹爪姿态及接近空间的影响。	24
合计	三类工业作业条件	相同 8 件工件在三种条件下重复摆放；共 72 对双目图像，144 张 RGB。	72

3.4 基线方法

基线分为点云基线与抓取基线，分别替换双目深度估计模块和六自由度抓取生成模块。选择策略兼顾技术路线覆盖、接口适配性和复现条件：点云方法覆盖传统几何匹配到预训练神经网络，抓取方法覆盖几何采样与评分、直接预测和生成模型；各方法能够接入双目图像或米制点云接口，并具有公开实现及可获取的必要预训练参数，以便记录和复核实际配置。点云基线读取同一对校正图像，以相同标定将深度反投影为三维点；抓取基线读取共同点云接口并输出夹爪候选位姿。学习方法采用已归档的预训练权重进行推理。

感知比较形成七种双目方法与 GraspGen 的组合，抓取比较形成 FoundationStereo 与五种抓取模型的组合。两组共享 FoundationStereo 与 GraspGen，因此共有 $7 + 5 - 1 = 11$ 条不同配置。各配置围绕共同参照替换单个模块，用于比较固定另一模块时的替换效果。共享点云、候选和物理执行通过唯一任务标识关联。

3.4.1 点云基线

点云基线覆盖局部匹配、半全局优化、代价体网络、迭代更新和使用大规模预训练的双目方法。各方法均使用固定的点云反投影与目标提取步骤，因此比较对象是深度估计模块在共同接口下产生的工件点云。

1. StereoBM 使用局部窗口的图像匹配代价计算视差，不需要预训练权重。本文采用 OpenCV 实现，以 Konolige 的区域相关双目方法为技术背景 [7]，具体接口以 OpenCV 的 StereoBM 文档为准[2]。选择它作为局部匹配的简单参照，观察基本图像对应关系能够支持怎样的点云与抓取结果。
2. SGM 沿多个方向聚合匹配代价，并对视差变化施加平滑约束 [8]。本文使用 OpenCV StereoSGBM 实现并记录其参数，选择它代表无需预训练权重的半全局匹配，与 StereoBM 的局部匹配形成对照。

[2] https://docs.opencv.org/4.x/d9/dba/classcv_1_1StereoBM.html

3. PSMNet 通过空间金字塔池化提取多尺度上下文，再用三维卷积处理代价体 [9]。选择它代表利用三维卷积学习匹配代价的网络，作为传统方法与后续神经网络的比较参照。
4. GwcNet 将左右特征分组计算相关性，构造供后续网络处理的匹配代价体 [10]。选择它补充代价体的另一种构建方式，与 PSMNet 比较不同匹配表示下的工件表面恢复表现。
5. RAFT-Stereo 利用相关性信息和多层循环更新模块，逐步修正视差估计 [11]。选择它代表迭代视差估计方法，与代价体卷积网络比较点云质量及后续抓取表现。
6. IGEV-Stereo 将几何与上下文信息编码到体表示中，为视差初始化和迭代更新提供依据 [12]。选择它代表几何编码与循环更新相结合的方法，与 RAFT-Stereo 形成迭代估计路线中的对照。
7. FoundationStereo 结合大规模合成双目训练、单目视觉先验和上下文建模，面向跨场景的零样本双目匹配 [1]。选择它评价大规模预训练模型在工业工件上的直接迁移表现，并将其输出作为比较抓取模型时的固定感知输入。

3.4.2 抓取基线

抓取基线覆盖几何候选与学习评分、变分生成、接触点预测、直接位姿预测和扩散生成五类方案。这些方法输出候选夹法；运动规划与机械臂控制由共同执行程序完成。

1. GPD 在点云局部几何上采样平行夹爪候选，再利用学习得到的分类器评分 [15]。当前模块使用作者的几何描述子与预训练分类参数。选择它代表几何候选采样与学习评分相结合的方案，为后续位姿预测和生成模型提供参照。
2. 6-DOF GraspNet 利用变分自编码器生成候选，并通过评价网络评分和修正候选位姿 [13]。选择它代表基于潜变量采样的抓取生成方法，与 GraspGen 的扩散生成路线比较候选可用性和执行结果。
3. Contact-GraspNet 从观测点云中的接触点预测抓取方向、开口等参数，生成六自由度夹爪位姿 [6]。选择它代表以可见表面接触点为依据的抓取预测，考察局部观测几何如何对应可执行的夹持方案。
4. GraspNet-Baseline 使用 GraspNet-1Billion 论文及官方基线中的点云抓取预测网络，分解预测接近方向与抓取参数 [16]。选择它作为公开抓取基准中的直接位姿预测参照，评价该预测方式迁移到工业工件后的表现。
5. GraspGen 利用扩散模型生成抓取候选，并由经过 on-generator training 的判别器评分 [2]。选择它代表扩散生成与学习评分相结合的方案，复用公开权重，并将其作为比较双目感知方法时的固定抓取模块。

神经网络采用已归档的作者权重进行推理。PSMNet 使用 KITTI 2015 权重，GwcNet 与 IGEV-Stereo 使用 Scene Flow 权重，RAFT-Stereo 使用 Middlebury 权重，FoundationStereo 使用归档的 23-51-11 检查点。StereoBM 的匹配窗口为 15，StereoSGBM 的窗口为 5，两者视差范围均为 192；神经网络运行参数和检查点哈希随模型记录共享。点云与候选批次使用归档种子，GPD 的采样种子为 20261011，其余本轮模型入口的种子为 0。比较结果对应这些权重、预处理和适配设置。

各基线保留原始候选、分数和适配后的夹爪坐标；评分仅用于模型内部排序。配置表记录仓库提交、权重哈希、输入分辨率、采样设置、夹爪坐标映射和推理设备。

3.5 实验环境

共同感知接口输出米制场景点云和目标区域点云，并保留相机到工位坐标变换。目标提取使用固定三维区域、预测高度超过桌面 3 mm 及近邻离群过滤，每条抓取候选提供位姿、开口和评分。共同路径程序限制夹爪朝下且偏离竖直不超过 45°，开口为 2–80 mm；依据预测点云检查两指接触区域，以及从初始位姿到预抓取点的关节插值、120 mm 直线接近和 150 mm 直线抬升。环境点云采用 3 mm 占据体素，关节与直线采样间隔分别约为 1° 和 5 mm。该程序没有绕障搜索，结果分别记录候选筛除、逆运动学失败、碰撞和预算超时。

三个仿真实验环境由机械臂与仿真器的组合定义，包含两种机械臂模型和两种物理仿真器，见表 2。Isaac Sim 环境采用 5.1 版本、Isaac Lab 2.3.2.post1 与 PhysX，分别加载 FANUC M-20iD/25 模型和原生 Franka Panda。MuJoCo 环境采用 3.3.7 版本及 Menagerie 的 Franka Panda 模型；所有环境使用平行两指工具。工件初始化后的位姿由重力、夹指和场景接触产生的动力学过程更新。完整流程包括接近、闭合、抬升、保持、降回、松开和退出。

三个环境复用已归档的双目输出与抓取候选，FANUC 和 Franka 分别生成符合各自运动学约束的计划。两个 Franka 环境执行相同关节路径；FANUC 与 Franka 的比较按场景、感知方法和抓取模型匹配，保留各自已选候选和路径。各环境分别通过夹持正例、夹空、夹爪不闭合和障碍阻挡校验；1244 次执行均已有结果及轨迹。机器人结构、原生碰撞资产、惯性、驱动和接触求解实现的差别作为完整环境配置记录。

表 2: 三个仿真实验环境。每个环境均覆盖相同的 72 个场景。执行次数包含默认与较低摩擦条件，排除孤立夹爪测试及校准。

环境	机械臂与工具	已选计划	物理执行次数
FANUC + Isaac Sim	M-20iD/25 模型+ Panda 两指工具	206	412
Franka + Isaac Sim	Isaac 原生 Franka Panda	208	416
Franka + MuJoCo	Menagerie Franka Panda	208	416

三个环境中每件物体质量统一为 0.1 kg，默认滑动摩擦系数设为 1.0，较低摩擦条件为 0.5；实际材料与接触参数随环境配置归档。夹指驱动力上限为每指 20 N，指关节 PD 参数为 1000/100，时间步为 1/250 s。FANUC 的臂关节 PD 为 $10^6/10^5$，两个 Franka 环境为 400/80；各环境沿用其归档的驱动和动作阶段设置。Franka 前四个臂关节的力矩上限为 87 N m，后三个为 12 N m；Isaac 中的 Franka 原生高增益配置关闭机器人重力，MuJoCo 对 Franka 启用重力补偿，工件均受重力作用。碰撞门禁每物理步计算，位姿与接触轨迹按 50 Hz 保存；环境版本、材料读回和模型来源纳入复现配置。

完整执行通过要求工件底部距原支承面至少 100 mm 并保持 2 s，接近末端误差不超过 2 mm 和 0.5°，并且除初始化稳定阶段外的完整动作流程没有超过 0.5 N 的禁止接触合力。物理抬升保持、接近到位和禁止接触分别保留布尔结果，联合判定作为执行通过。放回精度另列：相对稳定初始位置的平面误差不超过 20 mm，工件底部距台面不超过 3 mm。当前禁止接触使用非夹指连杆合力及夹指非目标接触合力，逐接触点覆盖的限制见节 7.3。

历史 GraspDataGen 评价保持原候选相对位姿和已保存的闭合指令，在无桌面、关闭重力的条件下施加五段 1 g 拉拽。该测试报告抗扰动夹持通过率，完整机械臂测试报告任务执行结果。孤立

夹爪测试只显式改变对象材料，夹爪沿用作者 USD 材料；完整机械臂材料条件覆盖机器人和场景的已读回碰撞形状。两类测试按各自的外力、支承和材料条件并行报告诊断结果。

3.6 评价指标

评价指标分别描述几何输入质量和抓取任务完成情况。以下以 i 表示场景，以 $\mathbf{1}[\cdot]$ 表示条件成立时取 1、否则取 0 的指示函数；距离以毫米报告，比例以百分数报告。

3.6.1 点云质量

深度误差衡量目标像素上的预测深度与真实深度之差。设 Ω_i 为左图中具有有效真值深度的目标像素集合，V_i 为方法输出的有效深度像素集合，$D_i = \Omega_i \cap V_i$；$\hat{z}_i(u)$ 和 $z_i^*(u)$ 分别为像素 u 的预测深度与真值深度。平均绝对深度误差和有效深度比例定义为

$$E_i^{\mathrm{depth}} = \frac{1}{|D_i|} \sum_{u \in D_i} |\hat{z}_i(u) - z_i^*(u)|, \qquad v_i^{\mathrm{depth}} = \frac{|D_i|}{|\Omega_i|}.$$

误差仅在有预测值的目标像素上计算，因此必须同时报告有效深度比例；D_i 为空时误差记为缺测。深度误差的 P95 为上述绝对误差样本的第 95 百分位数。

三维表面误差衡量输入抓取模型的目标点云偏离真实工件表面的程度。设 $\mathcal{P}_i = (\mathbf{p}_{ij})_{j=1}^{n_i}$ 为经过接口校验的目标点序列，n_i 为点数，$\mathcal{S}_i$ 为同一工位坐标系中的真实目标网格表面。点到表面的最近距离及平均表面误差定义为

$$d(\mathbf{p}, \mathcal{S}_i) = \min_{\mathbf{x} \in \mathcal{S}_i} \|\mathbf{p} - \mathbf{x}\|_2, \qquad E_i^{\mathrm{surface}} = \frac{1}{n_i} \sum_{j=1}^{n_i} d(\mathbf{p}_{ij}, \mathcal{S}_i).$$

表面误差的 P95 为这组点到表面距离的第 95 百分位数；点数、非有限坐标数和重复点数分别记录。

近表面点占比和可见表面覆盖率分别衡量预测点的准确程度与观测表面的完整程度。设 τ 为距离阈值，$\mathcal{Q}_i = (\mathbf{q}_{ik})_{k=1}^{m_i}$ 为左右相机真值目标深度反投影后拼接的表面采样点序列，则

$$p_i(\tau) = \frac{1}{n_i} \sum_{j=1}^{n_i} \mathbf{1}[d(\mathbf{p}_{ij}, \mathcal{S}_i) \le \tau], \qquad c_i(\tau) = \frac{1}{m_i} \sum_{k=1}^{m_i} \mathbf{1}\left[\min_j \|\mathbf{q}_{ik} - \mathbf{p}_{ij}\|_2 \le \tau\right].$$

采样点按两个视角的有效目标像素拼接，不做面积加权或重叠表面去重，因此覆盖率针对左右可见表面的采样点。阈值采用 1、2、5 mm，主表使用 2 mm。目标点云为空时点数和两个比例记为 0，表面误差记为缺测；真值可见采样为空时覆盖率记为缺测。

目标来源比例衡量提取的目标点云中有多少点实际来自目标像素。令 $M_i(u)$ 为左图真值目标掩码，$\pi_i(\mathbf{p})$ 为使用标定参数将三维点投影并取整到左图的像素坐标，则

$$t_i = \frac{1}{n_i} \sum_{j=1}^{n_i} M_i(\pi_i(\mathbf{p}_{ij})).$$

该比例与点到表面距离分别计算；非目标像素产生的预测点也可能落在工件表面附近。空目标点云的来源比例记为缺测。真值掩码、深度和网格仅供离线评价使用。

3.6.2 抓取成功率与阶段通过率

抓取成功要求工件被抬起并保持、夹爪接近到位，且执行流程满足禁止接触约束。设 $h_i(t)$ 为工件在时刻 t 的最低网格顶点距原支承面的高度，H_i 为规定保持阶段的采样时刻集合，抬升保持标签为

$$L_i = \mathbf{1}\left[\min_{t\in H_i} h_i(t) \geq h_{\min}\right], \qquad h_{\min} = 100 \text{ mm}.$$

保持阶段为 2 s，位姿记录频率为 50 Hz；该标签以完整保持记录为计算前提。令 $\mathbf{x}_i, \mathbf{R}_i$ 为接近结束时的实际夹爪位置与旋转矩阵，$\mathbf{x}_i^*, \mathbf{R}_i^*$ 为计划中的对应位姿。位置误差与旋转误差定义为

$$e_i^{\text{pos}} = \|\mathbf{x}_i - \mathbf{x}_i^*\|_2, \qquad e_i^{\text{rot}} = \arccos\left(\frac{\operatorname{tr}((\mathbf{R}_i^*)^\top \mathbf{R}_i) - 1}{2}\right).$$

数值计算将反余弦的输入截断到 $[-1, 1]$。接近到位标签为

$$A_i = \mathbf{1}[e_i^{\text{pos}} \leq \epsilon_p \ \wedge \ e_i^{\text{rot}} \leq \epsilon_r], \qquad \epsilon_p = 2 \text{ mm}, \quad \epsilon_r = 0.5^\circ.$$

设 T_i 为排除初始化稳定阶段后的全部物理步，$f_i(t)$ 为该步记录的非夹指连杆接触合力与夹指非目标接触合力中的最大模长。禁止接触约束的通过标签为

$$C_i = \mathbf{1}\left[\max_{t\in T_i} f_i(t) \leq F_{\max}\right], \qquad F_{\max} = 0.5 \text{ N}.$$

令 a_i 表示是否获得通过路径检查的已选计划。有计划且执行记录完整时，任务成功标签为 $s_i = L_i A_i C_i$，对应原始记录中的 `execution_success`；无候选、无可执行计划或算法超时的任务取 $s_i = 0$，物理夹持标签保持未测试。基础设施中断单列为待补记录，补齐后再统计完整任务组。

设 $\mathcal{I}$ 为某方法与环境配置下预定的场景集合，$N = |\mathcal{I}|$，$N_{\text{plan}} = \sum_{i\in\mathcal{I}} a_i$，$N_{\text{success}} = \sum_{i\in\mathcal{I}} s_i$。全场景抓取成功率、路径通过率和已有计划的条件抓取成功率分别定义为

$$r_{\text{grasp}} = \frac{N_{\text{success}}}{N}, \qquad r_{\text{plan}} = \frac{N_{\text{plan}}}{N}, \qquad r_{\text{grasp|plan}} = \frac{N_{\text{success}}}{N_{\text{plan}}}.$$

在全部计划均取得有效执行记录且 $N_{\text{plan}} > 0$ 时，三者满足

$$r_{\text{grasp}} = r_{\text{plan}}\, r_{\text{grasp|plan}}.$$

主要结果报告 r_{grasp} 及其成功数与分母；$N_{\text{plan}} = 0$ 时条件成功率记为缺测。候选数、空候选数、规划拒绝原因和执行失败阶段作为诊断记录。放回精度也单独记录：最终平面位置与稳定初始位置的欧氏距离为 e_i^{return}；补充的放回通过标签要求 $L_i = 1$、$e_i^{\text{return}} \leq 20$ mm，且放回保持阶段的各采样时刻均满足 $|h_i(t)| < 3$ mm。该标签不改变抓取成功率的定义。

几何指标先逐场景计算，再等权汇总。对任一有定义的逐场景指标 g_i，令 $\mathcal{I}_g \subseteq \mathcal{I}$ 为其非缺测场景集合，均值为

$$\bar{g} = \frac{1}{|\mathcal{I}_g|} \sum_{i\in\mathcal{I}_g} g_i.$$

缺测数与均值同时报告，点数另报中位数和范围。抓取成功率始终使用预定任务集合的完整分母。两个配置在同一场景集合上的成功率差以百分点表示，定义为 $\Delta = 100(r_{\text{grasp}}^{(a)} - r_{\text{grasp}}^{(b)})$。

方法间的成功率差值按相同工件、位姿与场景条件配对计算。为保留同一工件九个场景的相关性，先对每件工件计算九个任务的平均成功标签，再对八件工件的配对差值取平均。置信区间采用

工件为单位的百分位 bootstrap，重采样 20,000 次，随机种子为 20261014，报告 2.5% 与 97.5% 分位数。配对检验枚举八件工件差值的全部 2^8 种符号翻转，以均值绝对值作为统计量，报告双侧精确 p 值。在固定抓取模型的十八项比较与固定感知方法的十二项比较内，分别采用 Benjamini–Hochberg 方法校正多重比较。这些结果是对当前工件集合的探索性分析；工件聚类保留了位姿复用关系，仍未覆盖不同工业零件来源的变化。

4 RQ1: Quality of Stereo-Derived Point Clouds

本节回答“不同双目感知方法生成的工件点云质量如何?”，确定进入抓取模型的几何信息具有怎样的误差、覆盖和目标纯度。

4.1 Motivation

感知阶段的异常会传递到候选生成和路径检查。因此首先分析抓取模型实际收到的目标点云，明确候选生成前的几何输入质量。这一分析为 RQ2 解释不同双目前端的下游表现提供场景级证据。

4.2 Analysis Method

对实验数据集全部 72 个场景的七种输出逐份核对点数、非有限坐标、单位、过滤前后变化和输入哈希。三维误差采用预测点到目标真值网格的距离；近表面点占比统计给定距离内的预测点比例；覆盖率以固定左右相机可见的真实目标表面采样点为分母。阈值采用已保存的 1、2、5 mm 评价档位，正文用 2 mm 汇总，其余用于敏感性说明。目标来源比例通过投回左图并读取离线实例身份计算，与表面距离分别报告。全部目标有效像素的深度误差与仅保留目标点的误差分开，以反映过滤的选择作用。

4.3 Results and Analysis

4.3.1 Point Count, Accuracy, and Coverage

现有 504 份点云均满足接口校验，目标点数范围为 1,531–32,581，超过接口的 128 点下限。表 3 说明满足点数要求后，各方法的近表面比例和可见覆盖仍存在差异。图 2 展示各方法在相同 72 个场景上的分布。PSMNet 的目标点数中位数为 22,682，但两毫米内点比例仅为 6.2%；FoundationStereo 的相应点数为 3,034，两毫米内点比例为 92.9%。因此，增加传入模型的点数并不必然增加有效表面信息。

表 3: 实验数据集的点云结果，每种方法 72 场景。点数为中位数，其余为逐场景指标的等权平均；覆盖率仅针对左右可见表面。

方法	目标点数	2 mm 内点（%）	2 mm 覆盖（%）	表面误差（mm）
StereoBM	7,367	31.6	67.8	30.30
SGM（StereoSGBM）	6,873	37.1	71.6	20.15
PSMNet	22,682	6.2	21.7	40.07
GwcNet	8,977	22.7	57.3	32.92
RAFT-Stereo	3,178	67.6	68.9	2.59
IGEV-Stereo	3,062.5	71.2	68.4	1.86
FoundationStereo	3,034	92.9	93.9	3.02

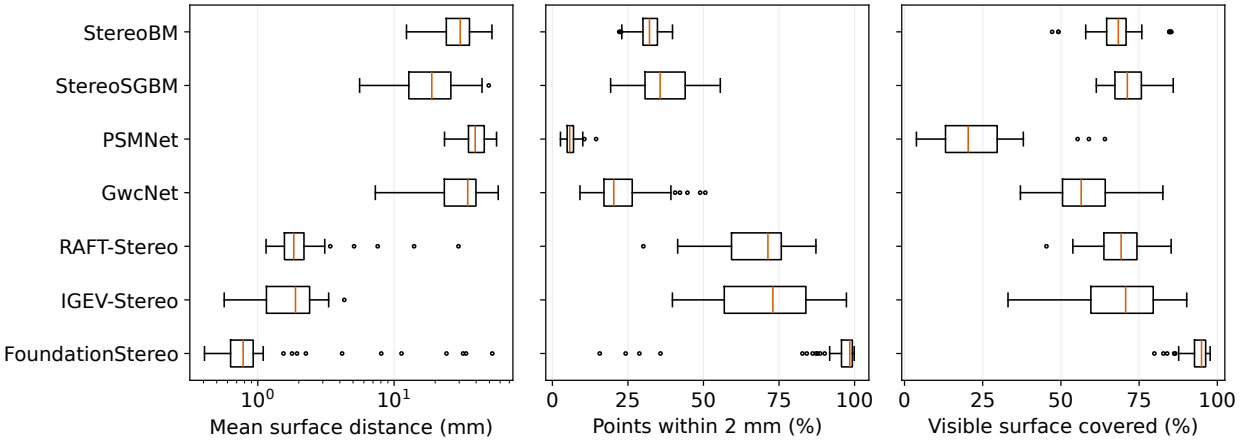


图 2: 七种双目方法的逐场景点云质量。每组包含相同的 72 个场景；左图的表面距离使用对数坐标，中图为两毫米近表面点比例，右图为左右可见目标表面的两毫米覆盖率。箱体表示四分位区间，中线为中位数，须线延伸至 1.5 倍四分位距内的观测，离群值单独显示。

4.3.2 Target Extraction and Outlier Cases

当前输出中，PSMNet 目标点来自真实目标像素的平均比例为 12.3%，FoundationStereo 为 95.1%，IGEV-Stereo 为 98.8%。固定空间区域与高度规则可能接收因深度误差移入区域的背景点，也可能接收邻件点。因此分别分析目标像素深度误差和非目标来源，区分双目匹配与目标提取对输入质量的影响。FoundationStereo 有 6/72 个场景的平均表面误差超过 5 mm，最大为 52.47 mm；该尾部现象有助于解释它的近表面比例与覆盖较高，但平均距离仍高于 IGEV-Stereo。

4.4 Answer to RQ1

实验结果表明，各方法点云均满足接口点数要求，但目标几何的误差和覆盖存在差异。FoundationStereo 在本批次的 2 mm 近表面点占比和覆盖率较高，IGEV-Stereo 的平均表面距离较小；若干方法的主要输入问题同时涉及深度误差与非目标点混入。这两项排序不同，说明工位选型应同时检查表面偏差、可见覆盖和非目标点比例，不能仅以点数或单一平均误差筛选前端。

5 RQ2: Effect of Stereo Perception on Grasping

本节回答“固定 GraspGen 时，不同双目感知方法的抓取效率如何?”，比较七种双目感知方法在三个环境、三种场景条件下的抓取成功率。

5.1 Motivation

固定抓取模块可以观察替换双目前端后流程结果怎样变化。这一比较包括共同目标提取和候选筛选的影响，能够检验几何指标较好的输入是否也带来更多可执行抓取。失败分析以具体场景的点云、候选与路径记录为依据。

5.2 Analysis Method

读取七种前端在 72 个场景上的 504 个任务，固定 GraspGen 权重与种子；每个仿真环境内固定工具、初始位姿、路径检查和控制设置。在 FANUC + Isaac Sim、Franka + Isaac Sim 和 Franka + MuJoCo 中分别评价，每环境按单件、邻件、料框分层。比较矩阵为七种感知方法、三种场景条件与三个环境；每格包含八件工件的三个位姿，共 24 个任务。先报告有候选和通过路径检查的场景数，再关联各环境的全部物理结果；FANUC 有 156 条已选计划，两个 Franka 环境各有 160 条。全场景抓取成功率以每方法、每环境的 72 场景为分母，分场景条件时以 24 为分母；条件成功率以该组已选计划数为分母。默认与较低摩擦条件在各环境内保持原计划，材料敏感性作为本问的补充分析。

5.3 Results and Analysis

5.3.1 From Point Clouds to Executable Plans

七种双目前端与 GraspGen 的全部 504 个任务都返回了非空候选，但路径阶段保留的任务数不同，见表 4。StereoBM、StereoSGBM 和 PSMNet 在 FANUC 上分别只有 1、6 和 8 个任务得到计划；FoundationStereo 有 51 个，Franka 上进一步增加至 52 个。这说明前三种组合的低成功率在物理执行之前就受到路径阶段筛选的影响，而非完全由模拟器中的夹持判断造成。同一任务可能有多个候选因不同约束被拒绝，因此逐候选拒绝次数只用于诊断，不与任务失败数相加。

表 4: 固定 GraspGen 的候选和计划阶段结果。每种双目前端有 72 个任务；两个 Franka 物理引擎复用同一份计划。

双目方法	非空候选任务	FANUC 已选计划	Franka 已选计划
StereoBM	72	1	1
StereoSGBM	72	6	6
PSMNet	72	8	9
GwcNet	72	22	23
RAFT-Stereo	72	38	38
IGEV-Stereo	72	30	31
FoundationStereo	72	51	52

较低的点云误差与较高的任务成功率之间并非一一对应。IGEV-Stereo 的平均表面距离小于 FoundationStereo，但其两毫米可见覆盖为 68.4%，后者为 93.9%，两者的目标表面信息分布不同。在共同筛选和规划设置下，FoundationStereo 保留更多可执行任务。这些观察支持同时检查覆盖与误差的必要性；本轮未单独控制覆盖率进行消融，因而将其解释为阶段关联。

5.3.2 Grasping Success in Three Environments

表 5 按三种环境展示各双目方法的默认材料结果。FoundationStereo 与 GraspGen 的成功数分别为 42/72、52/72 和 17/72，在当前三个环境中均高于其余双目前端组合。

与 IGEV-Stereo 相比，FoundationStereo 的成功率差值依次为 33.3、44.4 和 12.5 个百分点。工件配对 bootstrap 的 95% 区间分别为 [18.1, 48.6]、[26.4, 56.9] 和 [−2.8, 26.4] 个百分点；符号翻转检验的原始 p 值分别为 0.015625、0.015625 和 0.203125，多重比较校正后为 0.028125、0.028125 和 0.203125。第三个平台的差值区间包含零，提示当前八件工件上的观测排序仍伴随较大的工件间变化。

表 5: RQ2 默认材料下的抓取成功结果，固定 GraspGen。每种方法、每个环境均有 72 场景，包含三种场景条件各 24 个。每格给出成功数 / 总场景数及成功率，抓取成功需满足抬升保持、到位与禁止接触判定。

双目方法	FANUC + Isaac Sim	Franka + Isaac Sim	Franka + MuJoCo
StereoBM	0/72（0.0%）	0/72（0.0%）	0/72（0.0%）
SGM（StereoSGBM）	0/72（0.0%）	0/72（0.0%）	0/72（0.0%）
PSMNet	0/72（0.0%）	0/72（0.0%）	0/72（0.0%）
GwcNet	2/72（2.8%）	3/72（4.2%）	0/72（0.0%）
RAFT-Stereo	17/72（23.6%）	16/72（22.2%）	7/72（9.7%）
IGEV-Stereo	18/72（25.0%）	20/72（27.8%）	8/72（11.1%）
FoundationStereo	42/72（58.3%）	52/72（72.2%）	17/72（23.6%）

5.3.3 Scene Conditions and Failure Localization

表 6 汇总三种场景条件，各环境每种条件包含七种方法的 168 个任务。图 3 进一步给出逐方法结果，每个“方法–条件”单元以 24 为分母。汇总表用于描述当前任务矩阵，场景难度比较保持方法、工件和位姿匹配。

表 6: RQ2 默认材料下按场景条件汇总的抓取成功计数。每格分母为七种方法各 24 个任务；同一场景被不同方法使用，统计推断保留这种配对关系。

场景条件	FANUC + Isaac Sim	Franka + Isaac Sim	Franka + MuJoCo
单件	20/168	25/168	8/168
邻件	33/168	34/168	13/168
料框	26/168	32/168	11/168

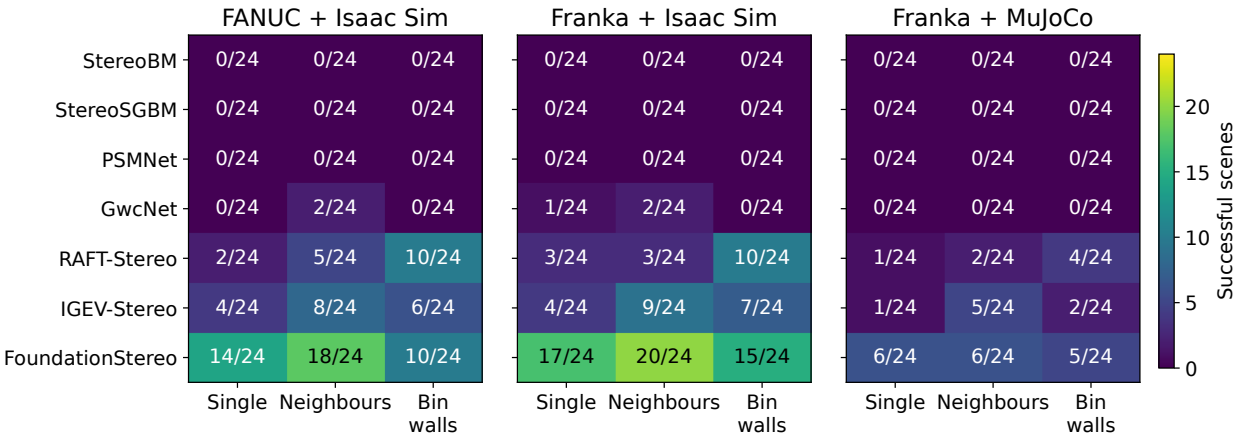


图 3: 固定 GraspGen 时，七种双目方法在三种场景条件和三个平台中的默认材料抓取成功数。每格为成功数 / 24，统一色标用于比较同一方法和条件在不同平台的变化。

按表中环境顺序，默认材料下成功数为 79/504、91/504、32/504，较低摩擦下为 49/504、52/504、22/504。FoundationStereo 与 GraspGen 在 Franka + Isaac Sim 的条件成功率为 52/52，全场景成功率为 52/72，两个分母分别报告。前者说明入选计划在该平台中均通过了物理执行，后者同时保留了二十个未通过规划的场景。邻件条件的合并成功数在三个平台均高于单件条件；这与“增加邻件必然降低成功率”的直觉不同。邻件同时改变了输入点云、候选排序和支承接触，当前数据记录的是这些变化后的联合结果，不能仅用障碍数量解释场景难度。

5.4 Answer to RQ2

在固定 GraspGen 和当前规划设置下，不同双目前端的抓取成功率随方法及环境变化。FoundationStereo 组合在三个环境中取得较多成功场景，但绝对成功率分别为 58.3%、72.2% 和 23.6%。七种组合均生成候选，而可执行计划数和计划执行后的成功比例不同。因而，感知模块的任务价值需要在候选、规划与物理执行的连续阶段中评价。

6 RQ3: Comparison of Grasp Generation Modules

本节回答“固定 FoundationStereo 时，不同抓取模型的抓取成功率如何?”，比较相同 FoundationStereo 输入下五种抓取模型在三个环境、三种场景条件下的成功率。

6.1 Motivation

即使点云完全相同，不同模型也会给出不同朝向、开口和分布的候选。这些候选在统一夹爪和接近限制下的可用性，与原模型的内部评分是不同的评价对象。本问关注现有模型作为可替换模块接入工业机械臂流程后的实际表现。

6.2 Analysis Method

在相同 72 个 FoundationStereo 点云上比较五个模型，共 360 个前端任务，并分别在三个仿真环境中评价。比较矩阵为五种抓取模型、单件 / 邻件 / 料框三种场景条件和三个环境，每个单元有 24 个任务。固定感知结果，每个环境内固定世界坐标、工具、路径检查和执行协议，核对各适配器的轴定义、宽度单位、工具偏移与候选排序。记录模型原生要求及共同约束造成的筛除，区分空候选、运行异常和没有通过规划的候选。FANUC 有 101 条已选计划，两个 Franka 环境各有 100 条，均已有物理结果。GraspGen 在各环境中的任务直接复用 RQ2 的对应证据；全场景成功率的分母为每模型 72，分场景条件为每模型 24。

6.3 Results and Analysis

6.3.1 Candidate Availability and Plan Acceptance

固定相同点云后，各模型在候选可用性与计划阶段仍表现不同，见表 7。Contact-GraspNet 有 6 个任务未返回候选，GraspNet-Baseline 有 23 个；GPD、6-DOF GraspNet 与 GraspGen 的 72 个任务均返回候选。6-DOF GraspNet 在两种机械臂上均仅有 1 个任务通过计划检查，Contact-GraspNet 均为 2 个。因此，这两种模型在本次系统中的低全场景成功率主要受限于候选到计划的保留比例，不能直接解释为它们生成的每一个抓取在物理上都无法夹持。

表 7: 固定 FoundationStereo 的候选与计划阶段。每模型有 72 个任务，空候选和未获得计划的任务仍计入全场景成功率分母。

抓取模型	非空候选任务	FANUC 已选计划	Franka 已选计划
GPD	72	41	41
6-DOF GraspNet	72	1	1
Contact-GraspNet	66	2	2
GraspNet-Baseline	49	6	4
GraspGen	72	51	52

GPD 的四个规划超时作为该配置的失败保留，没有以成功为条件重新采样替换结果。各模型原生坐标和夹爪几何不同，适配器统一轴方向、指尖平面与开口语义；共同朝下约束与夹爪模型进一步限定了可接入工位的候选。本轮比较反映的是这些适配与约束下的系统配置表现。

6.3.2 Grasping Success in Three Environments

默认材料下，GraspGen 在三个环境分别成功 42/72、52/72 和 17/72；GPD 分别成功 18/72、19/72 和 2/72。

GraspGen 相对 GPD 的差值分别为 33.3、45.8 和 20.8 个百分点，对应的工件配对 95% bootstrap 区间为 [15.3, 51.4]、[27.8, 59.7] 和 [8.3, 31.9]。双侧精确 p 值分别为 0.0234375、0.015625 和 0.046875，校正后为 0.034091、0.026786 和 0.046875。这一差异同时包含计划保留和执行阶段的变化。例如，在 FANUC 中，GPD 的入选计划成功比例为 18/41，而 GraspGen 为 42/51；Franka + MuJoCo

的相应比例为 2/41 和 17/52。

表 8: RQ3 默认材料下的抓取成功结果，固定 FoundationStereo。每模型、每环境均有 72 场景，包含三种场景条件各 24 个。每格给出成功数 / 总场景数及成功率；GraspGen 与 RQ2 共享对应环境的任务和物理记录。

抓取模型	FANUC + Isaac Sim	Franka + Isaac Sim	Franka + MuJoCo
GPD	18/72 (25.0%)	19/72 (26.4%)	2/72 (2.8%)
6-DOF GraspNet	1/72 (1.4%)	1/72 (1.4%)	0/72 (0.0%)
Contact-GraspNet	2/72 (2.8%)	2/72 (2.8%)	1/72 (1.4%)
GraspNet-Baseline	1/72 (1.4%)	1/72 (1.4%)	1/72 (1.4%)
GraspGen	42/72 (58.3%)	52/72 (72.2%)	17/72 (23.6%)

6.3.3 Scene Conditions and Failure Localization

表 9 列出三种场景条件的合并计数，图 4 展示逐模型结果，每个单元以 24 为分母。先在同一环境内比较模型，再观察同一模型的结果随邻件、料框与环境配置怎样变化。

表 9: RQ3 默认材料下按场景条件汇总的抓取成功计数。每格包含五种模型各 24 个任务；推断与失败分析按模型、工件和对应位姿配对。

场景条件	FANUC + Isaac Sim	Franka + Isaac Sim	Franka + MuJoCo
单件	21/120	24/120	6/120
邻件	29/120	32/120	8/120
料框	14/120	19/120	7/120

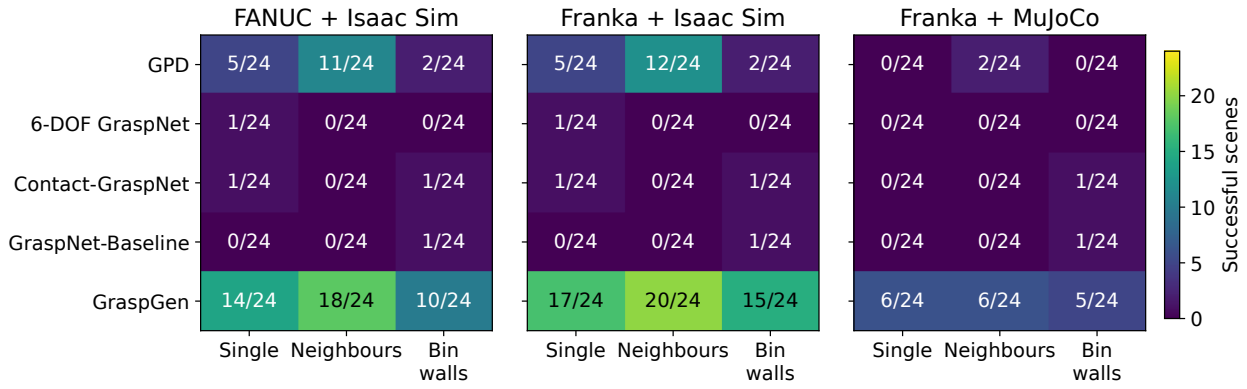


图 4: 固定 FoundationStereo 时，五种抓取模型的默认材料逐条件成功数。每格使用相同的八件工件、三个位姿，共 24 个场景。GraspGen 的对应记录与感知比较共享。

按表中环境顺序，默认材料下成功数为 64/360、75/360、21/360，较低摩擦下为 41/360、44/360、20/360。GPD 与 GraspGen 都存在进入物理执行后未能完成任务的计划；这一部分失败与空候选或路径筛除分别记录。两个 Franka 环境中的不一致结果可追溯到同一关节计划；涉及 FANUC 的比

较还需考虑机器人结构、候选选择及驱动设置。GraspDataGen 孤立夹爪抗扰动记录作为补充诊断，结合支承、动态接触与受力方向解释夹持结果。

6.4 Answer to RQ3

在固定 FoundationStereo 和当前工具、规划设置下，不同抓取模型在三个环境中的成功率存在差异。GraspGen 的默认全场景成功率分别为 58.3%、72.2% 和 23.6%，GPD 分别为 25.0%、26.4% 和 2.8%。其他模型在候选到已选计划阶段保留下来的任务较少，这一阶段的筛除与最终成功率一并分析。固定较好的几何输入仍不能消除抓取模块和执行平台的差异；低候选保留率优先对应适配及规划检查，已选计划失败则需要进一步核对接触和夹持条件。

7 Discussion

7.1 对工业界的启示

工业部署应根据各阶段证据定位抓取失败，再选择需要调整的模块。目标点来源比例偏低时，优先验证预测目标分割和桌面去除；候选在共同规则中大量被筛除时，核查夹爪坐标、开口语义和模型原生夹爪条件；路径形式限制较强时，另设绕障规划与接近方向对照；到位后滑落或碰撞时，结合接触记录检查工具几何、驱动与材料假设。对每条失败任务记录最早阻断阶段，同时保留闭合、碰撞、宽度与超时等并存事件。

默认摩擦条件下，对十一种配置的去重任务统计显示，FANUC 的 206 个已执行计划均达到末端到位要求，但有 90 个未通过抬升保持，20 个出现禁止接触，最终成功 101 个；Franka + Isaac Sim 的对应数字为 208、94、4 和 114，Franka + MuJoCo 为 208、170、6 和 36。抬升与接触失败可能重叠，这些数值按不同判据分别统计。末端到位而工件未被稳定抬起的记录说明，后续排查应同时检查闭合位置、夹爪几何和物理参数，而不能把全部失败归结为控制接口未执行命令。上述改进在独立批次中评价，真实控制器接口与硬件通信另行验证。

方法选择应以工业工位的全场景抓取成功率及失败类型为依据。同一配置分别报告单件、邻件和料框条件，每种条件均以 24 个场景为分母，观察遮挡、接近空间和壁面对结果的影响。环境间分歧较大的方案应优先检查夹爪碰撞形状、摩擦、驱动与工件质量，并用真实工件进行小规模验证后确定部署配置。

7.2 对学术界的启示

抓取方法研究需要同时报告几何输入、候选、计划和物理抓取结果，明确阶段指标与最终成功率的关系。全部场景的成功率保留无法生成计划的情况，已有计划的条件成功率用于分析执行阶段。跨环境实验复用前端输入与候选，在运动学模型相同时进一步复用计划，公开逐任务配对记录及不一致案例，使算法变化与环境变化能够分别核查。同一工件的重复位姿、共享方法组合和多个仿真结果按任务标识配对，并按工件聚合。

后续研究优先采用能够区分竞争解释的受控实验。点云侧比较现有目标提取与冻结的预测分割，真值点云或真值掩码只作为单列的诊断上界；抓取侧比较同一候选集合在原路径限制与新增绕障搜索下的差异；执行侧在固定候选下检查时间步、摩擦和夹指驱动的敏感性。后续可增加简单几何夹

持启发式作为任务基线，在相同接口、预算和评价条件下比较。由本次结果提出的改进应在新增独立工件上验证，保持原始配置与失败记录可复查。

7.3 Threats to Validity

7.3.1 Internal Validity

坐标、单位、夹爪偏移、模型适配及缓存对应错误会改变阶段结果。采用带哈希的输入输出关联、关节与末端位姿核对、正负校准例及原始接触轨迹复算控制这些风险。共同目标区域和朝下约束可能对不同方法产生不同影响，后续通过独立消融检查其作用。物理参数和代码的修正保留版本，校准、实现诊断及主要实验分别计数。

7.3.2 External Validity

当前数据只有两类程序化工业形状，表面为哑光渲染，尚未覆盖真实金属反光、传感器噪声、透明材料和随机堆叠。已归档预训练模型在本任务上保持冻结，其训练数据来源与合成资产的潜在相似性需要在模型清单中核对。FANUC 与 Franka 模型、平行两指工具、统一质量和未由真机辨识的驱动参数限定了仿真结果的外推范围。扩展工件、预测感知噪声和真实硬件测试是检验部署效果的后续步骤。

7.3.3 Construct Validity

点数、表面误差、候选评分、路径通过和物理任务完成测量不同对象，论文分别定义其分母与用途。可见覆盖只针对左右视角，完整执行的成功条件同时包含抬升和接触门禁。当前接触合力可能因相反方向的接触而抵消，后续应补充逐接触点检查及自碰覆盖审计。GraspDataGen 抗扰动、单独物理抬升和本文规定的抓取成功使用不同判定条件，分析中分别报告。三个环境同时涉及机器人结构、驱动、碰撞资产与接触求解差异，结果按完整环境配置解释。

7.3.4 Conclusion Validity

同一工件的多个位姿、不同种子和共享点云之间存在相关性，方法结果按场景配对、按工件及形状来源聚合。当前工件覆盖两个形状族，类别间比较采用描述性统计。本文按工件聚类报告配对差值、bootstrap 区间与多重比较校正，但只有八件工件，符号翻转检验的分辨率及区间稳定性受样本规模限制。这类统计结果用于描述当前配置比较；独立几何来源与重复随机运行仍是扩大推断范围所需的证据。依据已观察结果调整的问题与参数按探索性分析报告，并记录修订时间与数据使用范围。

8 Conclusion

本文通过三个研究问题比较了双目点云质量、固定 GraspGen 时的感知方法表现，以及固定 FoundationStereo 时的抓取模型表现。72 个合成工业场景的结果表明，点数充足的点云仍可能存在表面误差、覆盖不足和非目标点混入；在给定工具与规划设置下，感知和抓取模块的选择均影响最终

成功率。FoundationStereo 与 GraspGen 组合在默认材料条件下，在 FANUC + Isaac Sim、Franka + Isaac Sim 和 Franka + MuJoCo 中的成功率分别为 58.3%、72.2% 和 23.6%，表明同一模块组合的执行表现随实验环境配置而变化。因此，面向工业机械臂的方法选择应联合考察点云质量、路径可执行性和物理抓取结果，并保留逐任务的阶段记录以定位失败原因。

未来工作将扩展独立工业工件和场景，纳入真实金属表面、相机噪声及更复杂的遮挡条件，并在冻结配置后开展重复评价。进一步搭建标定双目相机与工业机械臂组成的硬件环境，测量夹爪、摩擦和控制参数，对照仿真与真实抓取的逐任务结果，检验方法差异能否在真实工位中保持。针对已发现的失败类型，将分别评价目标点提取、候选适配和运动规划的改进，使各模块的调整具有独立的实验依据。

参考文献

[1] B. Wen, M. Trepte, J. Aribido, J. Kautz, O. Gallo, and S. Birchfield, "FoundationStereo: Zero-Shot Stereo Matching," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025, pp. 5249–5260. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2025/html/Wen_FoundationStereo_Zero-Shot_Stereo_Matching_CVPR_2025_paper.html

[2] A. Murali, B. Sundaralingam, Y.-W. Chao, W. Yuan, J. Yamada, M. Carlson, F. Ramos, S. Birchfield, D. Fox, and C. Eppner, "GraspGen: A Diffusion-based Framework for 6-DOF Grasping with On-Generator Training," in *IEEE International Conference on Robotics and Automation*, 2026. [Online]. Available: https://research.nvidia.com/labs/lpr/publication/murali2026graspgen/

[3] P. Wu, A. Escontrela, D. Hafner, K. Goldberg, and P. Abbeel, "DayDreamer: World Models for Physical Robot Learning," in *Proceedings of The 6th Conference on Robot Learning*, ser. Proceedings of Machine Learning Research, vol. 205. PMLR, 2023, pp. 2226–2240. [Online]. Available: https://proceedings.mlr.press/v205/wu23c.html

[4] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, X. Chen, K. Choromanski, T. Ding, D. Driess, A. Dubey, C. Finn, P. Florence, C. Fu, M. Gonzalez Arenas, K. Gopalakrishnan, K. Han, K. Hausman, A. Herzog, J. Hsu, B. Ichter, A. Irpan, N. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, I. Leal, L. Lee, T.-W. E. Lee, S. Levine, Y. Lu, H. Michalewski, I. Mordatch, K. Pertsch, K. Rao, K. Reymann, M. Ryoo, G. Salazar, P. Sanketi, P. Sermanet, J. Singh, A. Singh, R. Soricut, H. Tran, V. Vanhoucke, Q. Vuong, A. Wahid, S. Welker, P. Wohlhart, J. Wu, F. Xia, T. Xiao, P. Xu, S. Xu, T. Yu, and B. Zitkovich, "RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control," in *Proceedings of The 7th Conference on Robot Learning*, ser. Proceedings of Machine Learning Research, vol. 229. PMLR, 2023, pp. 2165–2183. [Online]. Available: https://proceedings.mlr.press/v229/zitkovich23a.html

[5] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, S. Jakubczak, T. Jones, L. Ke, S. Levine, A. Li-Bell, M. Mothukuri, S. Nair, K. Pertsch, L. X. Shi, J. Tanner, Q. Vuong, A. Walling, H. Wang, and U. Zhilinsky, "π_0: A Vision-Language-Action Flow Model for General Robot Control," in *Proceedings of Robotics: Science and Systems*, 2025. [Online]. Available: https://www.roboticsproceedings.org/rss21/p010.html

[6] M. Sundermeyer, A. Mousavian, R. Triebel, and D. Fox, "Contact-GraspNet: Efficient 6-DoF Grasp Generation in Cluttered Scenes," in *IEEE International Conference on Robotics and Automation*, 2021. [Online]. Available: https://elib.dlr.de/145798/

[7] K. Konolige, "Small Vision Systems: Hardware and Implementation," in *Robotics Research*, Y. Shirai and S. Hirose, Eds. Springer, 1998, pp. 203–212. [Online]. Available: https://link.springer.com/chapter/10.1007/978-1-4471-1580-9_19

[8] H. Hirschmüller, "Stereo Processing by Semiglobal Matching and Mutual Information," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 30, no. 2, pp. 328–341, 2008. [Online]. Available: https://elib.dlr.de/55367/

[9] J.-R. Chang and Y.-S. Chen, "Pyramid Stereo Matching Network," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018, pp. 5410–5418. [Online]. Available: https://openaccess.thecvf.com/content_cvpr_2018/html/Chang_Pyramid_Stereo_Matching_CVPR_2018_paper.html

[10] X. Guo, K. Yang, W. Yang, X. Wang, and H. Li, "Group-wise Correlation Stereo Network," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019, pp. 3273–3282. [Online]. Available: https://openaccess.thecvf.com/content_CVPR_2019/html/Guo_Group-Wise_Correlation_Stereo_Network_CVPR_2019_paper.html

[11] L. Lipson, Z. Teed, and J. Deng, "RAFT-Stereo: Multilevel Recurrent Field Transforms for Stereo Matching," in *International Conference on 3D Vision*, 2021, pp. 218–227. [Online]. Available: https://collaborate.princeton.edu/en/publications/raft-stereo-multilevel-recurrent-field-transforms-for-stereo-matc/

[12] G. Xu, X. Wang, X. Ding, and X. Yang, "Iterative Geometry Encoding Volume for Stereo Matching," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 21 919–21 928. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2023/html/Xu_Iterative_Geometry_Encoding_Volume_for_Stereo_Matching_CVPR_2023_paper.html

[13] A. Mousavian, C. Eppner, and D. Fox, "6-DOF GraspNet: Variational Grasp Generation for Object Manipulation," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2019, pp. 2901–2910. [Online]. Available: https://openaccess.thecvf.com/content_ICCV_2019/html/Mousavian_6-DOF_GraspNet_Variational_Grasp_Generation_for_Object_Manipulation_ICCV_2019_paper.html

[14] J. Mahler, J. Liang, S. Niyaz, M. Laskey, R. Doan, X. Liu, J. Aparicio Ojea, and K. Goldberg, "Dex-Net 2.0: Deep Learning to Plan Robust Grasps with Synthetic Point Clouds and Analytic Grasp Metrics," in *Proceedings of Robotics: Science and Systems*, 2017. [Online]. Available: https://roboticsproceedings.org/rss13/p58.html

[15] A. ten Pas, M. Gualtieri, K. Saenko, and R. Platt, "Grasp Pose Detection in Point Clouds," *The International Journal of Robotics Research*, vol. 36, no. 13–14, pp. 1455–1473, 2017. [Online]. Available: https://journals.sagepub.com/doi/10.1177/0278364917735594

[16] H.-S. Fang, C. Wang, M. Gou, and C. Lu, "GraspNet-1Billion: A Large-Scale Benchmark for General Object Grasping," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020, pp. 11 444–11 453. [Online]. Available: https://openaccess.thecvf.com/content_CVPR_2020/html/Fang_GraspNet-1Billion_A_Large-Scale_Benchmark_for_General_Object_Grasping_CVPR_2020_paper.html